

Laporan Praktikum 2 Data Mining

Praproses Data

Nama : Muhammad Azka Ananta Khairon

NRP : 5054251004

1. Deskripsi Dataset

Dataset yang digunakan dalam praktikum ini adalah House Prices - Advanced Regression Techniques yang diperoleh dari platform Kaggle. Dataset ini berisi informasi mengenai harga penjualan rumah beserta berbagai atribut fisik dan kualitatifnya (seperti ukuran, lokasi, kondisi, dan tahun pembuatan).

- Sumber Data : <https://www.kaggle.com/competitions/house-prices-advanced-regression-techniques/data?select=train.csv>
- Ukuran Data Awal: 1460 Baris, 81 Kolom

2. Langkah-Langkah & Hasil Praproses Data

a. Pembersihan Data (Data Cleaning & Imputation)

Terdapat 19 fitur yang memiliki missing values dengan jumlah dan persentase sebagai berikut:

	jumlah_kosong	persen_kosong	tipe_data
LotFrontage	259	17.74	float64
Alley	1369	93.77	object
MasVnrType	872	59.73	object
MasVnrArea	8	0.55	float64
BsmtQual	37	2.53	object
BsmtCond	37	2.53	object
BsmtExposure	38	2.60	object
BsmtFinType1	37	2.53	object
BsmtFinType2	38	2.60	object
Electrical	1	0.07	object
FireplaceQu	690	47.26	object
GarageType	81	5.55	object
GarageYrBlt	81	5.55	float64
GarageFinish	81	5.55	object
GarageQual	81	5.55	object
GarageCond	81	5.55	object
PoolQC	1453	99.52	object
Fence	1179	80.75	object
MiscFeature	1406	96.30	object

Gambar 1. Tabel ringkasan missing values

Penanganan missing values dilakukan dengan beberapa metode di antaranya:

i. Kolom dengan Missing Value > 50%

Terdapat 4 kolom yang memiliki proporsi data kosong melebihi 50%, yaitu 'PoolQC' (99.52%), 'MiscFeature' (96.30%), 'Alley' (93.77%), 'Fence' (80.75%), dan 'MasVnrType' (59.73%). Keempat kolom ini dihapus sesuai dengan ketentuan prosedur pembersihan.

ii. Fitur Kategorikal

Missing values pada kolom kategorikal seperti 'BsmtQual', 'BsmtCond', 'FireplaceQu', 'GarageType', 'GarageFinish', 'GarageQual', dan 'GarageCond'

diimputasi dengan string 'None' karena missing values disebabkan karena ketiadaan fasilitas tersebut (bukan data yang hilang/error). Sedangkan fitur 'Electrical' diimputasi menggunakan modus (nilai yang paling sering muncul).

iii. Fitur Numerik

'LotFrontage' diimputasi menggunakan nilai median yang dikelompokkan berdasarkan variabel 'Neighborhood', 'GarageYrBlt' diisi dengan nilai 'YearBuilt', dan 'MasVnrArea' diimputasi dengan nilai median.

b. Deteksi dan Penanganan Outlier

Visualisasi boxplot menghasilkan temuan beberapa fitur seperti 'LotArea', 'SalesPrice', dan lain-lain memiliki outlier. Penanganan outlier dilakukan menggunakan metode Interquartile Range (IQR) dengan fungsi .clip(). Batas bawah (lower bound) disesuaikan menjadi minimal 0 untuk menjaga konsistensi variabel fisik yang tidak mungkin bernilai negatif.

$$\text{Lower Bound} = \max(0, Q1 - 1.5 \times \text{IQR})$$

$$\text{Upper Bound} = Q3 + 1.5 \times \text{IQR}$$

c. Transformasi Data

Data di dalam dataframe ditransformasi menggunakan dua metode, yaitu:

i. Standarisasi Fitur Numerik

Seluruh fitur numerik prediktor ditransformasi menggunakan StandardScaler dari pustaka scikit-learn untuk mengubah skala distribusi sehingga memiliki rata-rata ($\mu = 0$) dan standar deviasi ($\sigma = 1$).

ii. One-Hot Encoding

Fitur kategorikal diubah menjadi variabel biner (\$0\$ dan \$1\$) menggunakan pd.get_dummies()

	Id	MSSubClass	LotFrontage	LotArea	OverallQual	OverallCond	YearBuilt	YearRemodAdd	MasVnrArea	BsmtFinSF1	...	SaleType_Conw	SaleType_New	SaleType_Oth
0	1	0.131067	-0.249286	-0.333244	0.652644	-0.564161	1.053246	0.878668	0.795643	0.614224	...	False	False	False
1	2	-0.935733	0.583251	-0.013189	-0.073068	2.030907	0.156179	-0.429577	-0.667353	1.242296	...	False	False	False
2	3	0.131067	-0.082779	0.446022	0.652644	-0.564161	0.986797	0.830215	0.541858	0.106224	...	False	False	False
3	4	0.397766	-0.526798	-0.027104	0.652644	-0.564161	-1.870528	-0.720298	-0.667353	-0.517230	...	False	False	False
4	5	0.131067	0.805261	1.283733	1.378355	-0.564161	0.953572	0.733308	1.945140	0.496460	...	False	False	False

5 rows x 283 columns

Gambar 2. Hasil transformasi data

d. Reduksi Dimensi

Reduksi dimensi dilakukan melalui dua tahap, yaitu:

i. Eliminasi Multikolinearitas Tinggi

Menggunakan matriks korelasi, diidentifikasi pasangan fitur yang memiliki koefisien korelasi > 0.85 , lalu salah satu dari pasangan fitur tersebut dihapus untuk mengurangi redundansi informasi.


ii. Principal Component Analysis (PCA)

Teknik PCA diterapkan untuk memproyeksikan seluruh fitur numerik pendukung ke dalam 2 komponen utama (PC1 dan PC2) untuk kebutuhan visualisasi dan reduksi dimensi.

Fitur yang dihapus:
 ['GarageArea', 'Street_Pave', 'LotShape_Reg',
 Jumlah kolom sebelum eliminasi fitur: 283
 Jumlah kolom setelah eliminasi fitur: 256

	PC1	PC2	label
0	2.087708	0.637296	208500.0
1	0.023068	-1.451885	181500.0
2	2.385372	0.492480	223500.0
3	-0.553053	1.203339	140000.0
4	5.011049	1.419623	250000.0

Gambar 3. Hasil reduksi dimensi



Gambar 4. Scatter Plot 2D Principal Component Analysis (PC1 vs PC2)

3. Ringkasan Dataset Akhir Setelah Praproses

Berikut adalah perbandingan ringkas kondisi dataset sebelum dan sesudah tahap praproses data:

Parameter	Sebelum Pra Proses	Setelah Pra Proses
Jumlah Baris data	1460	1460
Jumlah Kolom	81	256 (setelah encoding dan reduksi)
Tota Missing Values	7829	0
Skala Fitur Numerik	Bervariasi (contoh 0 – 215.245)	Terstandarisasi ($\mu = 0$, $\sigma = 1$)
Outlier	Terdeteksi	Capped (IQR Bounds)