

Laporan Praktikum 1 Data Mining

Scraping & Eksplorasi Data (EDA)

Nama : Muhammad Azka Ananta Khairon

NRP : 5054251004

1. Deskripsi Dataset

Dataset ini diperoleh melalui proses web scraping menggunakan library requests dan BeautifulSoup dari situs domain publik Basketball-Reference. Data yang diambil mencakup seluruh direktori pemain profesional NBA dan BAA sepanjang sejarah dari indeks huruf A sampai Z.

- Sumber Data : <https://www.basketball-reference.com/players/>
- Jumlah Baris : 5416
- Jumlah Kolom : 8

Ringkasan Kolom

- “player” (nominal) : Nama lengkap pemain NBA. Berfungsi sebagai unique identifier.
- “from” (numerik diskrit) : Tahun pertama (debut) pemain di NBA.
- “to” (numerik diskrit) : Tahun terakhir pemain aktif.
- “pos” (nominal) : Posisi bermain (contoh: G, F, C, serta posisi hybrid seperti F-C dan G-F).
- “height” (numerik kontinu) : Tinggi badan pemain (data originalnya memiliki satuan feet-inches, tetapi sudah dikonversi ke sentimeter).
- “weight” (numerik kontinu) : Berat badan pemain dalam satuan pounds (lbs).
- “birth_date” (datetime) : Tanggal lahir pemain.
- “colleges” (nominal) : Nama kampus asal pemain.

2. Statistik Deskriptif

	count	mean	median	mode	std	min	25%	75%	max
from	5416.0	1991.03	1993.0	1968.0	23.59	1947.0	1972.0	2013.0	2026.0
to	5416.0	1995.27	1999.0	2026.0	24.26	1947.0	1976.0	2018.0	2026.0
height	5416.0	198.15	198.1	200.7	9.11	160.0	190.5	205.7	231.1
weight	5416.0	209.60	210.0	210.0	25.87	114.0	190.0	225.0	360.0

Tabel 1. Statistik Deskriptif Atribut Numerik

	count	unique	top	freq
pos	5416	7	G	1970
colleges	5011	1057	Kentucky	118

Tabel 2. Statistik Deskriptif Atribut Kategorikal

Analisis

- Nilai mean dan median height hampir sama persis, menandakan persebaran yang simetris.
- Terdapat jarak yang cukup jauh antara nilai median weight dengan nilai maksimumnya, mengindikasikan adanya outlier.
- Kolom colleges memiliki kardinalitas tinggi dengan 1057 unique value.
- Posisi Guard (G) merupakan kelompok terbanyak di liga dengan 1.970 pemain, sementara University of Kentucky menjadi kampus penyumbang pemain terbanyak sepanjang sejarah dengan total 118 alumni.

3. Penanganan Data

- Missing Values

o colleges

Terdapat 405 data kosong yang terjadi akibat string kosong (“”) pada pemain pemain yang masuk NBA langsung dari high school atau klub internasional. Penanganannya adalah dengan membuat kategori baru ‘No College / International’ untuk menjaga informasi dalam dataset tanpa membuang baris datanya.

o weight

Terdapat 5 pemain yang berat badannya tidak tercatat. Penanganannya adalah dengan imputasi nilai median berat badan berdasarkan tinggi badan pemain. Pendekatan ini dilakukan karena atribut tinggi dan berat badan memiliki korelasi linear yang kuat.

o birth_date

Terdapat 10 pemain yang data tanggal lahirnya tidak tercatat. Data dibiarkan kosong (NaT) tanpa imputasi atau drop row karena mengisinya dengan tanggal lahir palsu (seperti tanggal 1 Januari) akan menimbulkan bias pada analisis atribut, sedangkan menghapus barisnya akan membuang informasi valid lainnya dari pemain tersebut. Di samping itu, variabel ini bersifat opsional dan tidak mengganggu proses statistik deskriptif utama.

- Outlier

o height : Nilai terendah 160,0 cm dan tertinggi 231,1 cm.


o weight : Nilai tertinggi mencapai 360,0 lbs

Outlier ini tidak didrop karena nilai-nilai ekstrem ini dikonfirmasi sebagai fakta biologis/sejarah nyata di dunia olahraga NBA, bukan akibat kesalahan entri data atau kegagalan parsing. Outlier tetap dipertahankan agar tidak menghilangkan variasi postur fisik asli para pemain dalam dataset.


4. Visualisasi & Interpretasi

- Analisis Univariat

o Atribut Numerik



Gambar 1. Boxplot atribut numerik




Gambar 2. Histogram atribut numerik

Analisis:

1. Kolom height dan weight memiliki outlier yang memang benar terdapat pemain yang memiliki fisik unik dan di luar rata-rata fisik pemain pada umumnya.
2. Terdapat lonjakan nilai yang cukup tinggi pada nilai 2026 di kolom to. Hal tersebut sangat wajar karena mencakup jumlah pemain aktif yang masih bermain di NBA pada tahun 2026.
3. Terdapat lonjakan nilai yang besar pada nilai 1950 pada kolom from, karena mencakup seluruh pemain pada era awal pembentukan liga.
4. Terdapat lonjakan nilai yang besar dari periode akhir 1960 an hingga awal 1970, karena adanya ekspansi dan penambahan jumlah tim di NBA.

5. Terdapat dua puncak utama (bimodal) pada kolom height di sekitar 196 cm - 198 cm (rata-rata Guard/Forward) dan 203 cm - 206 cm (rata-rata Forward/Center).
6. Grafik weight meluruh pelan ke arah kanan hingga menyentuh angka 350+ lbs. Ini merepresentasikan sebagian kecil Center dengan bobot ekstrem di sejarah NBA.

○ Atribut Kategorikal




Gambar 3. Bar plot atribut kategorikal

Analisis:

1. Populasi pemain NBA di dominasi oleh posisi gurad murni (G) dan forward murni (F).
2. Kentucky menduduki urutan pertama sebagai kampus pencetak pemain NBA terbanyak, disusul Duke di peringkat kedua.

- Analisis Bivariat



Gambar 4. Analisis Bivariat

Analisis:

1. Tinggi pemain berkorelasi positif dengan berat badannya. Scatter plot menunjukkan bahwa pemain yang lebih tinggi cenderung memiliki massa tubuh yang lebih berat.
2. Rata-rata tinggi badan pemain NBA mengalami kenaikan tajam dari era awal (sekitar 189 cm pada tahun 1947) hingga menyentuh puncaknya di atas 202 cm pada pertengahan 1980-an (Golden Era/Big Men Era). Nilai ini kemudian perlahan menurun kembali di era modern (2010-2026) karena adanya evolusi permainan yang berfokus pada small ball dan tembakan 3 point.
3. Terdapat perbedaan fisik yang jelas di mana pemain dengan posisi center memiliki nilai median tinggi badan paling tinggi, disusul posisi-posisi hybrid, dan guard yang memiliki median paling rendah.